



Clasificación de Datos y Análisis de las V del Big Data: Mercado Bursátil de Tokio (JPX)

Iván David Cardzo Charry y Zara Melisa Monroy Vera

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Electiva VI Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel González Bonilla

Septiembre 11 de 2026





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

2.

Table de Contenidos

Abstract	3
Introducción	4
Objetivos	6
Marco teórico	7
Fuentes de datos y clasificación	9
V relevantes del Big Data.....	11
Reto de veracidad	12
Conclusiones	14
Referencia en formato IEEE	16

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Abstract

This report presents the second stage of a data science project applied to the Japanese equity market, focused on classifying the data sources required to predict stock returns and evaluating whether the resulting data landscape constitutes a Big Data scenario. Building on the business question and data requirements established in the previous stage, this document expands the data inventory to at least six sources drawn from the **JPX Tokyo Stock Exchange Prediction** dataset, published on Kaggle by Japan Exchange Group (JPX), classifying each source according to its level of structure structured, semi-structured, or unstructured [1], [2]. The analysis then applies the five V's framework volume, velocity, variety, veracity, and value to determine which dimensions are most critical to this project, concluding that variety and veracity are the most determinant characteristics given the combination of tabular financial records with complementary textual and disclosure-based sources [3]. Finally, a concrete data-veracity challenge is identified and a detection strategy is proposed, addressing the risk of temporal misalignment and missing values across sources of different granularity.

Keywords: *Data classification, Big Data, veracity, data quality, JPX Tokyo Stock Exchange.*





Introducción

Una vez encuadrado el proyecto de ciencia de datos en la etapa anterior definiendo la pregunta de negocio, los datos requeridos y la decisión que estos habilitarían, resulta necesario profundizar en la naturaleza de dichos datos antes de avanzar hacia el diseño de una arquitectura o la construcción de un modelo predictivo. No todos los datos que intervienen en un proyecto se comportan de la misma manera: algunos se organizan en esquemas tabulares rígidos, otros combinan cierta estructura con flexibilidad, y otros carecen por completo de un formato predefinido. Clasificar correctamente cada fuente según su nivel de estructura es un paso indispensable, ya que determina las herramientas y técnicas de procesamiento que serán necesarias más adelante.

Adicionalmente, cuando un proyecto involucra múltiples fuentes de datos heterogéneas, conviene evaluar si el caso constituye un escenario de **Big Data**, entendido no únicamente como un problema de gran volumen de información, sino como un fenómeno caracterizado por distintas dimensiones volumen, velocidad, variedad, veracidad y valor que pueden manifestarse con distinta intensidad según el contexto de negocio [3]. Identificar cuáles de estas dimensiones son críticas para un proyecto en particular permite anticipar los principales retos técnicos que deberán resolverse durante su desarrollo, entre ellos, los problemas de calidad o **veracidad** de los datos.

El presente documento retoma el caso de estudio del mercado bursátil de Tokio (Tokyo Stock Exchange, TSE), utilizando el dataset **JPX Tokyo Stock Exchange Prediction** publicado en



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

5.

Kaggle por Japan Exchange Group (JPX) [1], [2], con el propósito de ampliar el inventario de datos del proyecto, clasificar cada fuente según su nivel de estructura, justificar la relevancia de las V del Big Data en este caso particular, y señalar un posible problema de veracidad junto con la estrategia para detectarlo.

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Objetivos

1. Objetivo general

Clasificar las fuentes de datos disponibles para el proyecto de predicción de retornos en el mercado bursátil de Tokio según su nivel de estructura, y evaluar la relevancia de las cinco V del Big Data en este caso, con el fin de anticipar los principales retos de calidad de datos que deberán resolverse en las etapas posteriores del proyecto.

2. Objetivos específicos

- Listar al menos seis fuentes de datos del proyecto, clasificándolas como estructuradas, semiestructuradas o no estructuradas.
- Indicar cuáles de las cinco V del Big Data (volumen, velocidad, variedad, veracidad, valor) son críticas para este proyecto y justificar por qué.
- Señalar un posible problema de veracidad (calidad) en los datos del proyecto y describir cómo podría detectarse.

Marco teórico

La **clasificación de los datos según su nivel de estructura** constituye un concepto fundamental en ciencia de datos, ya que determina cómo debe almacenarse, procesarse y analizarse cada fuente de información. Los datos **estructurados** se organizan en un esquema fijo de filas y columnas, con tipos de dato claramente definidos, como ocurre en las bases de datos relacionales. Los datos **semiestructurados** combinan cierta organización con flexibilidad, careciendo de un esquema tabular rígido pero conservando etiquetas o metadatos que facilitan su interpretación, como ocurre en archivos JSON o XML. Los datos **no estructurados**, por su parte, carecen de un formato predefinido, como sucede con textos libres, imágenes, audio o video [3].

El término **Big Data** fue inicialmente caracterizado por Gartner a través de tres dimensiones volumen, velocidad y variedad antes de que IBM incorporara una cuarta dimensión, la veracidad, y posteriormente una quinta, el valor, dando origen al modelo ampliamente adoptado de las **cinco V's del Big Data** [3]. Según este modelo, el **volumen** se refiere a la escala de los datos generados; la **velocidad**, a la rapidez con la que estos fluyen hacia un sistema; la **variedad**, a la diversidad de tipos y fuentes de datos; la **veracidad**, a la calidad y confiabilidad de la información; y el **valor**, al beneficio de negocio derivado de su análisis [3]. No todo proyecto que involucra datos constituye necesariamente un caso de Big Data: es la combinación e intensidad de estas dimensiones lo que determina si un enfoque de Big Data resulta pertinente o no.



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

8.

Finalmente, la **veracidad** merece especial atención dentro de este marco, ya que se refiere específicamente a los problemas de calidad que pueden afectar la confiabilidad de un análisis: datos faltantes, inconsistentes, desactualizados o mal etiquetados. Detectar oportunamente estos problemas por ejemplo, mediante validaciones cruzadas entre fuentes o revisiones de completitud es indispensable antes de avanzar hacia etapas de modelamiento predictivo [3].

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Fuentes de datos y clasificación

A continuación, se presenta el inventario de al menos seis fuentes de datos identificadas para este proyecto, clasificadas según su nivel de estructura.

#	Fuente / Campo	Tipo de dato	Descripción breve
1	stock_prices.csv	Estructurado	Precio de cierre diario (OHLC) y columna target (retorno realizado) de ~2000 acciones del mercado japonés [2]
2	financials.csv	Estructurado	Resultados de reportes de ganancias trimestrales de las empresas listadas [2]
3	options.csv	Estructurado	Estado de diversas opciones basadas en el comportamiento del mercado japonés en general [2]
4	trades.csv	Estructurado	Resumen agregado de los volúmenes de negociación de la semana anterior [2]
5	stock_list.csv	Estructurado	Relación entre el código de cada acción, el nombre de la empresa y su industria [2]



6	Comunicados TDnet (Timely Disclosure Network) de la TSE	Semiestructurado	Documentos (PDF/XBRL) de divulgación de resultados y hechos relevantes, acompañados de metadatos tabulares (fecha, código, tipo de divulgación) [5]
7	Noticias financieras Nikkei/NQN sobre las empresas listadas	No estructurado	Texto narrativo libre generado por agencias de noticias sobre eventos corporativos, resultados y comentarios de mercado [6]

Justificación de la clasificación

Las fuentes 1 a 5 corresponden a archivos en formato CSV con esquema fijo de columnas y tipos de dato definidos, provenientes directamente del dataset preparado para la competencia [2]. La fuente 6 (comunicados TDnet) combina documentos de texto libre con metadatos estructurados asociados (fecha, código de empresa, tipo de divulgación), ubicándose en la categoría intermedia entre datos estructurados y no estructurados [4]. La fuente 7 (noticias financieras) corresponde a texto libre en lenguaje natural sin esquema fijo, lo que la clasifica como no estructurada [5].

V relevantes del Big Data

De las cinco V del Big Data volumen, velocidad, variedad, veracidad y valor [3], se identifican las siguientes como críticas para este proyecto:

V	¿Crítica?	Justificación
Volumen	Media	~2000 acciones × varios años de precios diarios, resultados financieros y datos de opciones [2]
Velocidad	Media	Actualización diaria (precios) y semanal (trading); no es tiempo real, por lo que un procesamiento batch es suficiente
Variedad	Alta	Combina datos estructurados (5 archivos CSV), semiestructurados (comunicados TDnet) y no estructurados (noticias financieras) [4], [5]
Veracidad	Alta	Riesgo de datos faltantes en reportes financieros y desalineación temporal entre archivos de distinta granularidad
Valor	Alta	El resultado impacta directamente decisiones de inversión con consecuencias económicas reales

Las V más críticas para este proyecto son **variedad** y **veracidad**, ya que la combinación de fuentes estructuradas, semiestructuradas y no estructuradas exige un esfuerzo de integración considerable, y dicha integración es precisamente el terreno donde surgen los principales riesgos de calidad de los datos.



Reto de veracidad

Como posible problema de veracidad (calidad) para este proyecto, se identifica el siguiente:

Desalineación temporal y valores faltantes entre archivos de distinta granularidad. Los reportes financieros trimestrales (financials.csv) pueden tener campos vacíos cuando una empresa aún no ha publicado su informe correspondiente a un periodo determinado, mientras que los comunicados de TDnet pueden divulgarse en fechas irregulares que no coinciden necesariamente con la actualización diaria de stock_prices.csv [2], [4]. Esta desalineación podría generar registros incompletos o inconsistentes al momento de integrar las distintas fuentes.

1. Cómo se detectaría

Este problema de veracidad podría detectarse mediante las siguientes acciones:

1. **Validación de completitud:** calcular el porcentaje de valores nulos o vacíos por columna en financials.csv, identificando qué empresas o periodos presentan mayor cantidad de datos faltantes.
2. **Validación cruzada de fechas:** comparar la fecha de divulgación de cada comunicado en TDnet contra la fecha de actualización de precios en stock_prices.csv, señalando los casos donde exista un desfase significativo entre ambas fuentes [4].



3. **Revisión de consistencia entre fuentes:** contrastar el código de empresa (SecuritiesCode) presente en stock_list.csv contra los códigos utilizados en financials.csv y trades.csv, para detectar posibles inconsistencias o registros huérfanos.

Detectar este tipo de problemas desde una etapa temprana del proyecto permite decidir con anticipación cómo tratar los datos faltantes o inconsistentes (por ejemplo, mediante imputación, exclusión de registros o marcado de baja confianza), evitando que estos problemas de calidad se propaguen hacia las etapas de análisis y modelamiento predictivo.





Conclusiones

El presente documento logró clasificar las fuentes de datos disponibles para el proyecto de predicción de retornos en el mercado bursátil de Tokio según su nivel de estructura, y evaluar la relevancia de las cinco V del Big Data en este caso, sentando las bases para anticipar los principales retos de calidad de datos que deberán resolverse en las etapas posteriores del proyecto.

Se listaron siete fuentes de datos del proyecto cinco archivos estructurados provenientes del dataset JPX Tokyo Stock Exchange Prediction, un comunicado semiestructurado de TDnet y noticias financieras no estructuradas, clasificándolas correctamente según su nivel de estructura y evidenciando que un mismo proyecto puede convivir con los tres tipos de datos simultáneamente [2], [4], [5].

Se indicó que, de las cinco V del Big Data, la **variedad** y la **veracidad** son las más críticas para este proyecto: la variedad, por la combinación de fuentes estructuradas, semiestructuradas y no estructuradas; y la veracidad, por los riesgos de datos faltantes y desalineación temporal entre archivos de distinta granularidad, justificando en ambos casos por qué son relevantes frente al volumen, la velocidad y el valor, que resultaron menos determinantes en este caso particular [3].

Finalmente, se señaló un problema concreto de veracidad la desalineación temporal y los valores faltantes entre financials.csv, TDnet y stock_prices.csv y se describieron tres acciones específicas para detectarlo: validación de completitud, validación cruzada de fechas y revisión de



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

15.

consistencia entre fuentes, lo cual constituye una base técnica sólida para el tratamiento de datos que se realizará en las etapas siguientes del proyecto.

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Referencia en formato IEEE

- [1] Kaggle, "JPX Tokyo Stock Exchange Prediction," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/overview>. [Accessed: Aug. 31, 2026].
- [2] Kaggle, "JPX Tokyo Stock Exchange Prediction — Data," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/data>. [Accessed: Aug. 31, 2026].
- [3] IBM, "What is Big Data?," *IBM Think*, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>. [Accessed: Aug. 31, 2026].
- [4] Japan Exchange Group, "Overview of TDnet," *JPX Official Website*, 2022. [Online]. Available: <https://www.jpx.co.jp/english/equities/listing/disclosure/tdnet/index.html>. [Accessed: Aug. 31, 2026].
- [5] QUICK Corp., "QUICK APIs — Data Coverage (Nikkei/NQN News)," *QUICK Corporate Website*, 2022. [Online]. Available: <https://corporate.quick.co.jp/en/apis/>. [Accessed: Aug. 31, 2026].

