



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Diseño de una Arquitectura de Datos: Mercado Bursátil de Tokio (JPX)

Iván David Cardzo Charry y Zara Melisa Monroy Vera

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Electiva VI Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel González Bonilla

Septiembre 11 de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

2.

Table de Contenidos

Abstract	3
Introducción	4
Objetivos	5
Marco teórico	6
Arquitectura propuesta	7
Herramientas candidatas por etapa.....	9
Conclusiones	10
Referencia en formato IEEE	11

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Abstract

This report presents the third stage of a data science project applied to the Japanese equity market, focused on designing the data architecture required to support the prediction of stock returns. Building on the business question, data inventory, and quality considerations established in the previous stages, this document proposes a complete data flow from sources, through ingestion and storage, to processing and business intelligence for the **JPX Tokyo Stock Exchange Prediction** dataset, published on Kaggle by Japan Exchange Group (JPX) [1], [2]. The architecture is justified in terms of two key design decisions: the choice between a data lake and a data warehouse, and the choice between batch and streaming ingestion, both determined by the update frequency and heterogeneity of the underlying sources [3]. A candidate tool is proposed for each stage of the pipeline ingestion, processing, and business intelligence with justification grounded in the specific characteristics of the data identified in earlier stages of the project.

Keywords: *Data architecture, data lake, data warehouse, batch processing, JPX Tokyo Stock Exchange.*



Introducción

Una vez identificadas y clasificadas las fuentes de datos del proyecto en la etapa anterior, y evaluados los riesgos de calidad asociados a su integración, corresponde ahora diseñar la **arquitectura de datos** que permitirá transformar dichas fuentes en información útil para el análisis. Una arquitectura de datos define el recorrido completo que sigue la información desde su origen hasta su uso final: cómo se capturan los datos, dónde se almacenan, cómo se procesan y cómo se ponen a disposición de los usuarios de negocio a través de herramientas de inteligencia de negocios (BI).

Diseñar esta arquitectura requiere tomar decisiones técnicas fundamentadas, entre ellas, si conviene almacenar los datos en un **data lake** o en un **data warehouse**, y si el procesamiento debe realizarse en modo **batch** o en modo **streaming**. Estas decisiones no son arbitrarias: dependen directamente de las características de los datos identificadas previamente, como su nivel de estructura, su frecuencia de actualización y su grado de heterogeneidad [3].

El presente documento retoma el caso del mercado bursátil de Tokio (Tokyo Stock Exchange, TSE) y su dataset **JPX Tokyo Stock Exchange Prediction** [1], [2], con el propósito de diseñar el flujo completo de arquitectura de datos fuentes, ingesta, almacenamiento, procesamiento y análisis/BI, justificar la elección entre lake/warehouse y batch/streaming, y proponer una herramienta candidata para cada etapa del proceso.



Objetivos

1. Objetivo general

Diseñar una arquitectura de datos completa para el proyecto de predicción de retornos en el mercado bursátil de Tokio, justificando las decisiones de almacenamiento y procesamiento con base en las características de las fuentes de datos identificadas en las etapas previas del proyecto.

2. Objetivos específicos

- Dibujar el flujo completo de la arquitectura de datos: fuentes → ingesta → almacenamiento → procesamiento → análisis/BI.
- Justificar la elección entre data lake y data warehouse, y entre procesamiento batch y streaming.
- Nombrar una herramienta candidata para cada etapa (ingesta, procesamiento, BI) y justificar su elección.





Marco teórico

Un **data lake** es un repositorio centralizado que permite almacenar grandes volúmenes de datos en su formato original estructurado, semiestructurado o no estructurado sin necesidad de transformarlos previamente, lo cual lo hace especialmente adecuado para escenarios con alta variedad de fuentes. Un **data warehouse**, en cambio, almacena datos ya estructurados, limpios y organizados según un esquema predefinido, optimizado para consultas analíticas rápidas y consistentes, pero menos flexible frente a datos heterogéneos [3].

Respecto al procesamiento, el enfoque **batch** consiste en procesar los datos por lotes, en intervalos programados (por ejemplo, una vez al día), lo cual resulta adecuado cuando la velocidad de actualización de los datos no exige una respuesta inmediata. El enfoque **streaming**, en cambio, procesa los datos de forma continua a medida que se generan, siendo necesario en escenarios donde la inmediatez es crítica, como el monitoreo de transacciones en tiempo real [3]. La elección entre uno u otro enfoque depende directamente de la velocidad con la que se actualizan las fuentes de datos del proyecto, una de las V del Big Data ya evaluada en la etapa anterior.

Arquitectura propuesta




Figura 1. Arquitectura de datos propuesta para la predicción de retornos en el mercado JPX.

Elaboración propia, asistida con IA (Claude, Anthropic).

Justificación: ¿Data lake o data warehouse?

Se recomienda un **data lake** para este proyecto, dado que las fuentes de datos combinan tres niveles de estructura distintos (estructurado, semiestructurado y no estructurado), tal como se identificó en la Semana 2 [4], [5]. Un data warehouse exigiría transformar y estructurar previamente las noticias financieras y los comunicados TDnet antes de almacenarlos, lo cual limitaría la flexibilidad del proyecto en sus etapas exploratorias iniciales. El data lake permite conservar los datos en su formato original y aplicar transformaciones específicas más adelante, según las necesidades del modelo predictivo.



Justificación: ¿Batch o streaming?

Se recomienda un enfoque **batch**, dado que las fuentes de datos del proyecto se actualizan con una frecuencia diaria (precios) o semanal (volúmenes de trading, comunicados TDnet) [2], [4], y no en tiempo real. Un enfoque de streaming implicaría una complejidad de infraestructura innecesaria para este caso, ya que la pregunta de negocio (predicción de retornos para construir un portafolio) no exige una respuesta inmediata al momento en que ocurre cada transacción, a diferencia de escenarios como la detección de fraude en tiempo real.



Herramientas candidatas por etapa

Etapa	Herramienta candidata	Justificación
Ingesta	Apache Airflow	Permite programar y orquestar cargas batch diarias/semanales desde múltiples fuentes (Kaggle, J-Quants API, TDnet), gestionando dependencias entre tareas de forma confiable
Procesamiento	Python (Pandas / PySpark)	Pandas es adecuado para el volumen moderado de este proyecto; PySpark permitiría escalar el procesamiento si el volumen de noticias y comunicados creciera significativamente
BI / Visualización	Power BI	Permite construir dashboards interactivos de ranking de retornos y comparación sectorial, con conexión directa a los datos ya procesados en el data lake

📍 Sede Quirinal: Calle 21 No. 6 - 01

📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220

📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699

✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co

Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989

NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Conclusiones

El presente documento logró diseñar una arquitectura de datos completa para el proyecto de predicción de retornos en el mercado bursátil de Tokio, justificando las decisiones de almacenamiento y procesamiento con base en las características de las fuentes de datos identificadas en las etapas previas del proyecto.

Se dibujó el flujo completo de la arquitectura de datos, desde las fuentes (archivos CSV de Kaggle, comunicados TDnet y noticias financieras) pasando por la ingesta batch, el almacenamiento en un data lake, el procesamiento y limpieza de los datos, hasta el análisis y visualización mediante herramientas de inteligencia de negocios.

Se justificó la elección de un **data lake** frente a un data warehouse, dado que las fuentes del proyecto combinan tres niveles de estructura distintos que exigirían una transformación previa innecesaria en un esquema de warehouse; asimismo, se justificó la elección de un enfoque **batch** frente a streaming, dado que ninguna de las fuentes del proyecto exige actualización en tiempo real.

Finalmente, se nombró una herramienta candidata para cada etapa del proceso Apache Airflow para la ingesta, Python/Pandas para el procesamiento y Power BI para la visualización, justificando cada elección con base en las características específicas de los datos y la escala del proyecto.



Referencia en formato IEEE

- [1] Kaggle, "JPX Tokyo Stock Exchange Prediction," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/overview>. [Accessed: Aug. 31, 2026].
- [2] Kaggle, "JPX Tokyo Stock Exchange Prediction — Data," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/data>. [Accessed: Aug. 31, 2026].
- [3] IBM, "What is Big Data?," *IBM Think*, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>. [Accessed: Aug. 31, 2026].
- [4] Japan Exchange Group, "Overview of TDnet," *JPX Official Website*, 2022. [Online]. Available: <https://www.jpx.co.jp/english/equities/listing/disclosure/tdnet/index.html>. [Accessed: Aug. 31, 2026].
- [5] QUICK Corp., "QUICK APIs — Data Coverage (Nikkei/NQN News)," *QUICK Corporate Website*, 2022. [Online]. Available: <https://corporate.quick.co.jp/en/apis/>. [Accessed: Aug. 31, 2026].