



Tipos de Analítica y Consideraciones Éticas: Predicción de Retornos en el Mercado Bursátil de Tokio (JPX)

Iván David Cardzo Charry y Zara Melisa Monroy Vera

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Electiva VI Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel González Bonilla

Septiembre 11 de 2026





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

2.

Table de Contenidos

Abstract	3
Introducción	4
Objetivos	5
Marco teórico	6
Las 4 preguntas por tipo de analítica.....	7
Supervisado o no supervisado	7
Riesgo ético y mitigación	8
Conclusiones	10
Referencia en formato IEEE	11

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Abstract

This report presents the fourth stage of a data science project applied to the Japanese equity market, focused on classifying the types of analytics relevant to the prediction of stock returns and identifying ethical risks associated with this process. Building on the business question, data architecture, and quality considerations established in the previous stages, this document formulates four questions one for each analytics type: descriptive, diagnostic, predictive, and prescriptive applied to the **JPX Tokyo Stock Exchange Prediction** dataset, published on Kaggle by Japan Exchange Group (JPX) [1], [2]. For the predictive and prescriptive components, **supervised machine learning** is identified as the appropriate approach, given the availability of a labeled target variable in the dataset. Finally, a concrete ethical risk is identified bias toward companies with greater historical data availability along with a mitigation strategy grounded in fairness principles applicable to data-driven financial decision-making [3].

Keywords: *Analytics types, supervised learning, algorithmic bias, data ethics, JPX Tokyo Stock Exchange.*





Introducción

Después de encuadrar el proyecto, clasificar sus fuentes de datos y diseñar su arquitectura, corresponde ahora precisar **qué tipo de analítica** se requiere en cada etapa del proceso de predicción de retornos, y reflexionar sobre los **riesgos éticos** que un proyecto de esta naturaleza puede introducir. No todas las preguntas que pueden formularse sobre un mismo conjunto de datos exigen el mismo tipo de análisis: algunas buscan describir el pasado, otras explicar por qué ocurrió algo, otras anticipar el futuro, y otras recomendar una acción concreta.

Asimismo, cuando un modelo de datos influye directamente en decisiones de inversión, es indispensable anticipar posibles sesgos que puedan afectar la equidad o confiabilidad de sus resultados, especialmente en un mercado donde no todas las empresas cuentan con la misma disponibilidad de información histórica.

El presente documento retoma el caso del mercado bursátil de Tokio (Tokyo Stock Exchange, TSE) [1], [2], con el propósito de formular cuatro preguntas una por cada tipo de analítica, justificar el uso de aprendizaje automático supervisado para los componentes predictivo y prescriptivo, y describir un riesgo ético concreto junto con su estrategia de mitigación.



Objetivos

1. Objetivo general

Clasificar los tipos de analítica aplicables al proyecto de predicción de retornos en el mercado bursátil de Tokio e identificar un riesgo ético asociado a su desarrollo, con el fin de anticipar tanto el enfoque técnico como las consideraciones de equidad necesarias antes de construir el modelo predictivo.

2. Objetivos específicos

- Escribir cuatro preguntas sobre el caso de estudio, una por cada tipo de analítica (descriptiva, diagnóstica, predictiva, prescriptiva).
- Indicar, para los componentes predictivo y prescriptivo, si se usaría aprendizaje automático supervisado o no supervisado, y justificar por qué.
- Describir un posible sesgo o riesgo ético del proyecto y proponer una estrategia para mitigarlo.

Marco teórico

De acuerdo con el modelo de madurez analítica ampliamente adoptado en la literatura de ciencia de datos, existen cuatro tipos de analítica que se diferencian según la pregunta que buscan responder: la **analítica descriptiva** responde a "¿qué pasó?"; la **analítica diagnóstica** responde a "¿por qué pasó?"; la **analítica predictiva** responde a "¿qué pasará?" empleando modelos de aprendizaje automático entrenados sobre datos históricos; y la **analítica prescriptiva** responde a "¿qué se debería hacer?", sugiriendo el mejor curso de acción a partir de los resultados de las etapas anteriores [4].

El **aprendizaje automático supervisado** consiste en entrenar un modelo a partir de datos históricos etiquetados, es decir, datos donde ya se conoce el resultado real (variable objetivo) con el fin de que el modelo aprenda a predecir dicho resultado sobre datos nuevos. El aprendizaje **no supervisado**, en cambio, se utiliza típicamente para tareas exploratorias sin variable objetivo, como agrupar elementos similares mediante *clustering* [4].

Finalmente, todo proyecto de ciencia de datos que influye en decisiones reales debe considerar sus **riesgos éticos**, entendidos como posibles sesgos, inequidades o efectos no deseados derivados del uso de los datos o del modelo. Un riesgo ético frecuente es el **sesgo por disponibilidad de datos**, que ocurre cuando un modelo aprende patrones más confiables para los elementos con mayor cantidad de información histórica, en detrimento de aquellos con menor cobertura [3].



Las 4 preguntas por tipo de analítica

Tipo de analítica	Pregunta
Descriptiva	¿Cuál fue el retorno promedio de las acciones del sector tecnológico japonés durante el último trimestre?
Diagnóstica	¿Por qué ciertas acciones tuvieron retornos negativos durante un periodo específico, según sus resultados financieros trimestrales?
Predictiva	¿Cuál será el retorno futuro de cada acción del mercado japonés en el próximo periodo de negociación?
Prescriptiva	¿Qué acciones se deberían incluir en el segmento de compra (top 200) y cuáles en el de venta (bottom 200) del portafolio?

Supervisado o no supervisado

Para los componentes **predictivo** y **prescriptivo** de este proyecto, se emplearía **aprendizaje automático supervisado**, dado que:

1. El dataset ya contiene una **variable objetivo-etiquetada** (la columna *target* de *stock_prices.csv*), que representa el retorno realizado de cada acción [2].

2. El objetivo del modelo es **aprender la relación** entre las variables predictoras (precios históricos, resultados financieros) y dicha variable objetivo, para luego generalizar esa relación a datos futuros.
3. El componente prescriptivo (el ranking de compra/venta) se deriva directamente de las predicciones del modelo supervisado, sin requerir un enfoque adicional no supervisado.

No se descarta el uso de aprendizaje **no supervisado** como técnica exploratoria complementaria (por ejemplo, agrupar acciones similares por comportamiento mediante *clustering* para apoyar la analítica diagnóstica), pero no constituye el enfoque principal para responder las preguntas predictiva y prescriptiva planteadas.

Riesgo ético y mitigación

Riesgo identificado: sesgo hacia empresas con mayor disponibilidad de datos históricos.

El modelo predictivo se entrenaría principalmente sobre `stock_prices.csv` y `financials.csv`; sin embargo, no todas las empresas listadas en la TSE cuentan con el mismo volumen de información disponible: las empresas grandes y de mayor capitalización tienden a tener series de precios más largas y reportes financieros más completos, mientras que empresas pequeñas o de reciente listado suelen tener menos historial disponible [2]. Esta asimetría podría provocar que el modelo genere predicciones menos confiables o sistemáticamente sesgadas para las empresas pequeñas, no por un



menor potencial de retorno real, sino simplemente por la menor cantidad de datos disponibles para modelarlas.

Mitigación propuesta:

- Segmentar la evaluación del modelo por tamaño de empresa (capitalización bursátil o antigüedad de listado), reportando métricas de desempeño separadas por segmento en lugar de una sola métrica agregada.
- Establecer un umbral mínimo de calidad de datos por acción, comunicando explícitamente qué acciones quedan fuera del alcance confiable del modelo, en lugar de forzar una predicción poco confiable [3].





Conclusiones

El presente documento logró clasificar los tipos de analítica aplicables al proyecto de predicción de retornos en el mercado bursátil de Tokio e identificar un riesgo ético asociado a su desarrollo, sentando las bases técnicas y de equidad necesarias antes de construir el modelo predictivo.

Se escribieron cuatro preguntas sobre el caso de estudio, una por cada tipo de analítica, evidenciando que un mismo proyecto puede requerir simultáneamente una mirada retrospectiva (descriptiva), explicativa (diagnóstica), anticipatoria (predictiva) y accionable (prescriptiva) sobre un mismo conjunto de datos [4].

Se indicó que, para los componentes predictivo y prescriptivo, correspondería utilizar aprendizaje automático **supervisado**, justificando esta elección en la disponibilidad de una variable objetivo etiquetada en el dataset, la cual permite entrenar y validar un modelo sobre el retorno real observado de cada acción [2].

Finalmente, se describió un riesgo ético concreto el sesgo hacia empresas con mayor disponibilidad de datos históricos y se propusieron dos estrategias de mitigación específicas: la segmentación de la evaluación del modelo por tamaño de empresa y el establecimiento de un umbral mínimo de calidad de datos, demostrando que las consideraciones éticas pueden abordarse de forma concreta y no solo teórica [3].



Referencia en formato IEEE

- [1] Kaggle, "JPX Tokyo Stock Exchange Prediction," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/overview>. [Accessed: Aug. 31, 2026].
- [2] Kaggle, "JPX Tokyo Stock Exchange Prediction — Data," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/data>. [Accessed: Aug. 31, 2026].
- [3] IBM, "What is Big Data?," *IBM Think*, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>. [Accessed: Aug. 31, 2026].
- [4] Qlik, "Embrace the Future — Make the Move from Descriptive to Prescriptive Analytics," *Qlik Blog*, 2022. [Online]. Available: <https://www.qlik.com/blog/embrace-the-future-moving-from-descriptive-to-prescriptive-analytics>. [Accessed: Aug. 31, 2026].

