



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Diagnóstico de Datos de un Proceso: Predicción de Retornos en el Mercado Bursátil de Tokio (JPX)

Zara Melisa Monroy Vera

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Electiva VI Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel González Bonilla

Agosto 30 de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

2.

Table de Contenidos

Abstract	3
Introducción	4
Objetivos	6
Marco teórico	7
Planteamiento del problema	10
Problem and Data	13
Inventario de datos	14
Tipo de analítica aplicada.....	17
¿Es un caso de Big Data? Justificación con las cinco V's	19
Ciclo de vida del proyecto.....	22
Comparación de enfoques con el trabajo del compañero.....	24
Conclusiones	27
Referencia en formato IEEE	29





Abstract

This report presents a data diagnosis for a real financial process: the construction of investment portfolios in the Japanese equity market. Institutional investors must decide, among roughly 2,000 stocks listed on the Tokyo Stock Exchange, which securities to buy or sell to maximize returns. The analysis is based on the **JPX Tokyo Stock Exchange Prediction** dataset, published on Kaggle by Japan Exchange Group (JPX), which provides structured data on prices, financial results, options, and trading volumes. The original files are complemented with semi-structured (TDnet disclosures) and unstructured (financial news) sources, completing a full data inventory across all three structure types. The problem is classified as **predictive analytics**, solved through **supervised machine learning**, with a secondary **prescriptive** output used to rank stocks for portfolio construction. Applying the five V's framework, variety and veracity — rather than raw volume — are identified as the most determinant Big Data characteristics. The complete data life cycle (question, obtain, clean, analyze, visualize, decide) is mapped onto the case, and this individual approach is formally compared against a complementary, independently developed approach based on institutional trading volume, both derived from the same dataset.

Keywords: *Big Data, ciencia de datos, analítica predictiva, aprendizaje automático supervisado, JPX Tokyo Stock Exchange.*



Introducción

El presente trabajo aborda el diagnóstico de datos de un proceso real dentro del contexto financiero: la toma de decisiones de inversión en el mercado bursátil japonés. En un entorno donde circulan diariamente miles de transacciones sobre cerca de 2000 acciones listadas en la Bolsa de Tokio (Tokyo Stock Exchange, TSE), los inversionistas institucionales enfrentan el reto constante de decidir qué valores comprar, mantener o vender con el fin de maximizar el retorno de sus portafolios. Este problema, lejos de ser trivial, requiere de la integración, limpieza y análisis sistemático de múltiples fuentes de datos precios históricos, resultados financieros, volúmenes de negociación y comportamiento del mercado de opciones para poder generar predicciones confiables que sustenten decisiones de inversión informadas.

Para desarrollar este diagnóstico se utilizó el conjunto de datos **JPX Tokyo Stock Exchange Prediction**, publicado en la plataforma Kaggle y organizado por Japan Exchange Group (JPX), la entidad que opera la Bolsa de Tokio, la Bolsa de Osaka y la Bolsa de Commodities de Tokio, con el apoyo técnico de la empresa AlpacaJapan Co., Ltd. [1]. Este dataset reúne información estructurada proveniente de los sistemas oficiales de datos de JPX (J-Quants API/Pro) [2], [3], la cual fue complementada en este trabajo con fuentes adicionales de tipo semiestructurado (comunicados oficiales de divulgación TDnet de la TSE) [4] y no estructurado (noticias financieras Nikkei/NQN sobre las empresas listadas) [5], con el propósito de construir un inventario de datos completo que abarque los tres tipos de estructura exigidos en la actividad.



Es importante aclarar el origen de este dataset dentro del desarrollo del curso: las actividades prácticas de las semanas 1 a 4 (formativas, opcionales) se desarrollaron **en pareja** con Iván David Cardozo Charry razón por la cual ambos trabajamos sobre el mismo conjunto de datos JPX Tokyo Stock Exchange Prediction desde el inicio del corte. Sin embargo, la actividad calificable del Corte 1 correspondiente a este documento es de **entrega individual**, por lo que, aunque **se mantiene el mismo dataset** ya explorado durante las semanas previas (evitando así partir de cero y aprovechando el trabajo conjunto ya realizado), cada integrante desarrolla su propia **pregunta de negocio y enfoque analítico independiente** sobre dicho conjunto de datos. En mi caso, el enfoque se centra en la **predicción del retorno futuro de cada acción para la construcción de un portafolio de inversión** (utilizando principalmente los archivos stock_prices.csv y financials.csv), mientras que el trabajo de mi compañero se enfoca en **el análisis de patrones de volumen de negociación institucional como señal anticipada de movimientos de precio** (utilizando principalmente el archivo trades.csv). Esta diferenciación de pregunta, enfoque y fuentes protagonistas garantiza que ambas entregas, aunque parten del mismo dataset por continuidad del trabajo en pareja, constituyen análisis individuales, independientes y complementarios, tal como se detalla en la sección de este documento.





Objetivos

1. Objetivo general

Diagnosticar la viabilidad y estructura de los datos disponibles en el conjunto **JPX Tokyo Stock Exchange Prediction**, con el fin de determinar su pertinencia para modelar y predecir el retorno futuro de acciones del mercado bursátil japonés, como insumo para la construcción de un portafolio de inversión basado en un ranking de retornos esperados.

2. Objetivos específicos

- **Formular** una pregunta de negocio clara y accionable sobre la predicción de retornos bursátiles, identificando los datos y fuentes necesarias para responderla, así como la decisión de inversión que dicho resultado permitiría tomar.
- **Elaborar** un inventario de al menos seis fuentes/campos de datos relacionados con el proceso analizado, clasificando cada una según su nivel de estructura (estructurado, semiestructurado o no estructurado).
- **Determinar** el tipo de analítica de datos (descriptiva, diagnóstica, predictiva o prescriptiva) aplicable al problema planteado, justificando su elección y evaluando si el caso constituye un escenario de Big Data mediante el análisis de las cinco V's (volumen, velocidad, variedad, veracidad y valor).
- **Diseñar** el ciclo de vida del proyecto de datos (pregunta → obtener → limpiar → analizar → visualizar → decidir) aplicado específicamente al caso de predicción de retornos en el mercado JPX, representándolo mediante diagramas de flujo.
- **Diferenciar** el enfoque analítico individual desarrollado en este documento del enfoque adoptado por el compañero/a de trabajo en pareja, evidenciando que, aunque ambos parten del mismo dataset, cada uno responde a una pregunta de negocio y a un uso de fuentes distinto.



Marco teórico

1. Ciencia de datos y su ciclo de vida

La ciencia de datos es un campo interdisciplinario que combina estadística, programación y conocimiento del dominio de negocio para extraer valor de conjuntos de datos, generalmente siguiendo un ciclo de vida estructurado que inicia con la formulación de una pregunta, continúa con la obtención y limpieza de los datos, y culmina en su análisis, visualización y uso para la toma de decisiones. Este ciclo pregunta, obtener, limpiar, analizar, visualizar, decidir constituye el marco metodológico central que se aplica en el presente trabajo al caso del mercado bursátil japonés.

2. Big Data y el modelo de las V's

El término *Big Data* fue inicialmente caracterizado por Gartner a través de tres dimensiones volumen, velocidad y variedad antes de que IBM incorporara una cuarta dimensión, la veracidad, y posteriormente una quinta, el valor, dando origen al modelo ampliamente adoptado de las **cinco V's del Big Data**: volumen, velocidad, variedad, veracidad y valor [9]. Según este modelo, el volumen se refiere a la escala de los datos generados; la velocidad, a la rapidez con la que estos fluyen hacia un sistema; la variedad, a la diversidad de tipos y fuentes (estructurados, semiestructurados y no estructurados); la veracidad, a la calidad y confiabilidad de la información; y el valor, al beneficio de negocio derivado del análisis [9]. Este marco teórico es el que se utiliza

en la sección 6 del presente documento para evaluar si el caso de predicción de retornos en el mercado JPX constituye o no un escenario de Big Data.

3. Tipos de analítica de datos

De acuerdo con el modelo de madurez analítica de Gartner, ampliamente adoptado en la literatura de ciencia de datos, existen cuatro tipos de analítica que se diferencian según la pregunta que buscan responder: la **analítica descriptiva** responde a "¿qué pasó?" mediante la agregación y visualización de datos históricos; la **analítica diagnóstica** responde a "¿por qué pasó?" mediante técnicas de correlación; la **analítica predictiva** responde a "¿qué pasará?" empleando modelos de aprendizaje automático entrenados sobre datos históricos; y la **analítica prescriptiva**, considerada el nivel más avanzado, responde a "¿qué se debería hacer?", sugiriendo el mejor curso de acción a partir de los resultados de las etapas anteriores [10]. En el presente trabajo, el proceso de predicción de retornos bursátiles se ubica principalmente en el nivel predictivo, con una salida final de carácter prescriptivo al recomendar qué acciones incluir en el portafolio.

4. Aprendizaje automático supervisado

El aprendizaje automático (*machine learning*) supervisado consiste en entrenar un modelo a partir de datos históricos etiquetados es decir, datos donde ya se conoce el resultado real (variable objetivo) con el fin de que el modelo aprenda a predecir dicho resultado sobre datos nuevos. En el caso del dataset JPX Tokyo Stock Exchange Prediction, la columna *target* de *stock_prices.csv*



representa el retorno real de cada acción, lo cual permite entrenar modelos supervisados de regresión o ranking para estimar el retorno futuro [2].

5. El mercado bursátil japonés y sus fuentes oficiales de datos

Japan Exchange Group (JPX) es la entidad que opera la Bolsa de Tokio (TSE), la Bolsa de Osaka (OSE) y la Bolsa de Commodities de Tokio (TOCOM) [3]. A través de su subsidiaria JPX Market Innovation & Research, Inc., JPX distribuye datos financieros históricos —precios, información corporativa y resultados de ganancias mediante servicios como J-Quants API/Pro [3], [7], mientras que la divulgación oportuna de información corporativa (resultados, dividendos, fusiones, entre otros) se canaliza oficialmente a través de TDnet (*Timely Disclosure Network*) [4]. Estas fuentes constituyen el respaldo institucional primario de los datos utilizados en el dataset de Kaggle analizado en este trabajo [1], [2].





Planteamiento del problema

Contexto del proceso

El mercado bursátil de Tokio (Tokyo Stock Exchange, TSE), operado por Japan Exchange Group (JPX), es uno de los mercados de valores más grandes del mundo, con cerca de 2000 acciones activamente negociadas que representan a empresas de prácticamente todos los sectores de la economía japonesa. En este entorno, los inversionistas institucionales fondos de pensiones, gestoras de activos, bancos de inversión enfrentan de manera recurrente un mismo problema operativo: decidir, entre miles de opciones disponibles, qué acciones comprar, mantener o vender en cada periodo de negociación, con el objetivo de maximizar el retorno de sus portafolios y minimizar el riesgo asumido.

Este proceso de decisión de inversión no puede sustentarse únicamente en la intuición o el análisis manual, dado el volumen y la velocidad con que se generan los datos del mercado (precios diarios, resultados financieros trimestrales, movimientos de opciones, volúmenes de negociación semanal). Por ello, se requiere de un enfoque sistemático de ciencia de datos que permita transformar esta información dispersa y heterogénea en una señal accionable: un ranking de acciones ordenadas de mayor a menor retorno esperado, que sirva como base objetiva para la construcción del portafolio.



Formulación del problema

El problema real que aborda este trabajo puede formularse de la siguiente manera:

¿Cómo puede un inversionista institucional decidir, de forma sistemática y basada en datos, qué acciones del mercado japonés incluir en la parte alta (compra) y cuáles en la parte baja (venta) de su portafolio, a partir del comportamiento histórico de precios, resultados financieros y actividad de negociación de dichas acciones?

Pregunta de datos

A partir del problema anterior, se plantea la siguiente pregunta de datos, que orienta todo el desarrollo del presente trabajo:

¿Es posible predecir el retorno futuro de cada acción del mercado bursátil japonés, utilizando datos históricos de precios, resultados financieros y variables de mercado, con el fin de generar un ranking que maximice la diferencia de retorno entre las 200 acciones con mejor desempeño esperado y las 200 con peor desempeño esperado?

Esta pregunta reproduce, en esencia, el reto de evaluación definido por la competencia original organizada por Japan Exchange Group (JPX) en colaboración con AlpacaJapan Co., Ltd. [1], en la cual el desempeño de los participantes se mide precisamente por dicha diferencia de retornos entre el segmento superior e inferior del ranking generado [1].

Relevancia del problema

Este problema es relevante desde una perspectiva de negocio por al menos tres razones:

1. **Impacto económico directo:** una predicción más precisa de retornos se traduce en decisiones de inversión más rentables y en una gestión de riesgo más eficiente para fondos e instituciones que operan en el mercado japonés.
2. **Escalabilidad del análisis:** con cerca de 2000 acciones a evaluar simultáneamente, resulta inviable un análisis manual; se requiere necesariamente de técnicas de ciencia de datos y aprendizaje automático para procesar la información a esa escala.
3. **Disponibilidad de datos reales y verificables:** al tratarse de datos históricos de precios que no son confidenciales y de información financiera divulgada oficialmente a través de canales regulados como TDnet [4], el problema es abordable con datos públicos y de fuente institucional confiable, lo cual permite validar y sustentar bibliográficamente cada etapa del análisis.

Decisión que habilita el resultado

El resultado de este análisis (el ranking predictivo de retornos) habilita directamente la siguiente decisión de negocio: determinar la composición de un portafolio de inversión, asignando posiciones largas (compra) a las acciones con mayor retorno esperado y posiciones cortas o de



exclusión (venta) a las acciones con menor retorno esperado, dentro de los límites de las 200 acciones superiores e inferiores del ranking [1].

Problem and Data

Institutional investors operating in the Japanese equity market face the recurring operational challenge of deciding which of roughly 2,000 stocks listed on the Tokyo Stock Exchange (TSE) to buy, hold, or sell during each trading period, in order to build a portfolio that maximizes expected return while managing risk [1]. Making this decision systematically, rather than intuitively, requires historical daily stock prices, quarterly corporate financial results, options market activity, and aggregated weekly trading volumes, all of which are provided through the JPX Tokyo Stock Exchange Prediction dataset hosted on Kaggle and originally sourced from Japan Exchange Group's official data infrastructure [1], [2], [3]. Beyond the six structured files included in the original dataset, this project also incorporates complementary data of a different nature: semi-structured corporate disclosure records published through TDnet, the TSE's official Timely Disclosure Network, and unstructured financial news covering the listed companies, so that the data inventory reflects the full range of structures typically found in a real business problem [4], [5]. The analytics type required to solve this problem is primarily **predictive analytics**, since the objective is to forecast the future return of each stock through a supervised machine learning model trained on historical patterns, using the labeled *target* column already present in `stock_prices.csv` [2]. A secondary **prescriptive** component is also present in the final stage of the process, because



the ultimate output is not merely a numerical forecast but an actionable ranking decision which stocks should occupy the top and bottom segments of the portfolio directly informing a concrete investment strategy [1]. Given the combination of structured, semi-structured, and unstructured sources, together with the need to reconcile data of different temporal granularities (daily prices versus weekly trading volumes and irregularly timed disclosures), this problem also raises meaningful **data veracity** and **variety** challenges that are characteristic of Big Data scenarios, even though the raw volume of the core dataset alone is comparatively modest [2].

Inventario de datos

A continuación, se presenta el inventario de las ocho fuentes/campos de datos identificados para este proyecto, clasificados según su nivel de estructura.

Fuente / Campo	Tipo de dato	Descripción breve	Referencia
stock_prices.csv	Estructurado	Precio de cierre diario (OHLC) y columna target (retorno realizado) de ~2000 acciones del mercado japonés	[2]
financials.csv	Estructurado	Resultados de reportes de ganancias trimestrales de las empresas listadas	[2]
options.csv	Estructurado	Estado de diversas opciones basadas en el comportamiento del mercado japonés en general	[2]



trades.csv	Estructurado	Resumen agregado de los volúmenes de negociación de la semana anterior	[2]
stock_list.csv	Estructurado	Relación entre el código de cada acción (SecuritiesCode), el nombre de la empresa y su industria	[2]
secondary_stock_prices.csv	Estructurado	Precios de valores menos líquidos, fuera de las 2000 acciones principales, útiles para evaluar el mercado en general	[2]
Noticias financieras Nikkei/NQN (titulares y notas de prensa sobre empresas listadas)	No estructurado	Texto narrativo libre, generado por agencias de noticias, sobre eventos corporativos, resultados y comentarios de mercado	[5]
Comunicados TDnet (Timely Disclosure Network) de la TSE	Semiestructurado	Documentos (PDF/XBRL) de divulgación de resultados y hechos relevantes, acompañados de metadatos tabulares (fecha, código de la acción, tipo de divulgación)	[4]

Justificación de la clasificación


Fuentes 1 a 6 Estructurado: todas corresponden a archivos en formato CSV, con esquema fijo de columnas, tipos de dato definidos (numéricos, fechas, códigos categóricos) y relaciones claras entre tablas (por ejemplo, SecuritiesCode como llave común entre stock_prices.csv y stock_list.csv). Estas fuentes provienen directamente del dataset preparado para la competencia [2], cuyo origen primario son los sistemas oficiales de datos de JPX, distribuidos a través de J-Quants API/Pro [3], [7].

Fuente 7 No estructurado: las noticias financieras no siguen un esquema fijo; son texto libre en lenguaje natural, sin columnas ni campos predefinidos, lo que exige técnicas de procesamiento de lenguaje natural (NLP) para extraer información útil (por ejemplo, sentimiento de mercado o menciones de eventos corporativos relevantes) [5].

Fuente 8 Semiestructurado: los comunicados de TDnet combinan un documento de texto libre (el contenido del informe, en PDF o XBRL) con un conjunto de metadatos estructurados asociados (fecha y hora de divulgación, código de la empresa, bolsa donde cotiza, título del comunicado) [4], lo que los ubica en la categoría intermedia entre datos estructurados y no estructurados.

Diagrama de flujo del inventario

Figura 1. Flujo de las ocho fuentes de datos hacia el pipeline de análisis y la decisión final de portafolio. Elaboración propia, asistida con IA (Claude, Anthropic).





Tipo de analítica aplicada

Clasificación según el modelo de madurez analítica

Aplicando el modelo de los cuatro tipos de analítica descriptiva, diagnóstica, predictiva y prescriptiva [10] al problema de predicción de retornos bursátiles planteado en este trabajo, se obtiene la siguiente clasificación:

Tipo de analítica	Pregunta que responde	¿Aplica al proyecto?	Justificación
Descriptiva	¿Qué pasó?	Sí (etapa de apoyo)	Se utiliza para caracterizar el comportamiento histórico de precios, volúmenes y resultados financieros antes de construir el modelo predictivo, mediante estadísticas descriptivas y visualizaciones de stock_prices.csv y financials.csv [2]
Diagnóstica	¿Por qué pasó?	Parcial	Permite explorar por qué ciertas acciones tuvieron retornos negativos o positivos, cruzando financials.csv con noticias financieras (fuente 7 del inventario) para identificar posibles causas [2], [5]
Predictiva	¿Qué pasará?	Sí — núcleo del proyecto	Se entrena un modelo de aprendizaje automático supervisado para estimar el retorno futuro de cada acción, utilizando la columna target de stock_prices.csv como variable objetivo [2]



Prescriptiva	¿Qué se debería hacer?	Sí (salida final)	El ranking resultante del modelo predictivo se traduce directamente en una recomendación de acción: qué acciones incluir en el top 200 (compra) y cuáles en el bottom 200 (venta) del portafolio [1]
---------------------	------------------------	-------------------	--

Tipo de aprendizaje automático: supervisado

Para la etapa predictiva del proyecto se emplearía **aprendizaje automático supervisado**, dado que:

1. El dataset ya contiene una **variable objetivo etiquetada** (la columna *target* de *stock_prices.csv*), que representa el retorno realizado de cada acción [2].
2. El objetivo del modelo es **aprender la relación** entre las variables predictoras (precios históricos, resultados financieros, volumen de negociación) y dicha variable objetivo, para luego generalizar esa relación a datos futuros no vistos.
3. El problema puede plantearse como una tarea de **regresión** (estimar el valor numérico del retorno) o de **ranking/aprendizaje para ordenar** (*learning to rank*), ambas dentro del paradigma supervisado, ya que en ambos casos se dispone del valor real contra el cual entrenar y validar el modelo.



No se considera pertinente el aprendizaje **no supervisado** como enfoque principal, ya que este se utiliza típicamente para tareas exploratorias sin variable objetivo (por ejemplo, agrupar acciones similares por comportamiento mediante *clustering*), lo cual podría emplearse como técnica complementaria de análisis exploratorio, pero no resuelve directamente la pregunta de predicción de retorno planteada en la sección Pregunta de datos.

Nivel de madurez analítica alcanzado

Siguiendo el modelo de madurez de Gartner, este proyecto se ubica en el nivel más avanzado del espectro analítico, ya que no se detiene en la comprensión del pasado (descriptiva) ni en la explicación de por qué ocurrió (diagnóstica), sino que avanza hacia la anticipación de eventos futuros (predictiva) y culmina en una recomendación concreta de acción (prescriptiva) [10]. Este recorrido de la mirada retrospectiva hacia la mirada prospectiva y accionable es justamente lo que le otorga mayor valor de negocio al proyecto frente a un análisis puramente descriptivo.

¿Es un caso de Big Data? Justificación con las cinco V's

Marco de referencia

Para determinar si este proyecto constituye un caso de Big Data, se aplica el modelo ampliamente adoptado por IBM y Gartner de las cinco V's: volumen, velocidad, variedad, veracidad y valor [9].



A continuación, se evalúa cada una en el contexto específico del proyecto de predicción de retornos bursátiles del mercado JPX.

Análisis por V

V	Nivel	Justificación
Volumen	Media-Alta	El dataset abarca ~2000 acciones principales más un conjunto adicional de valores secundarios, con precios diarios (OHLC) a lo largo de varios años, resultados financieros trimestrales y datos de opciones [2]. Al incorporar noticias (fuente 7) y comunicados TDnet (fuente 8), el volumen de datos textuales crece considerablemente [4], [5]
Velocidad	Media	Los precios se actualizan diariamente y los volúmenes de negociación semanalmente [2], [3]; no son datos en tiempo real, por lo que un procesamiento batch diario/semanal es suficiente y adecuado para este proyecto
Variedad	Alta	El inventario combina tres niveles de estructura: datos estructurados (6 archivos CSV), semiestructurados (comunicados TDnet en PDF/XBRL con metadatos) y no estructurados (noticias financieras en texto libre) [2], [4], [5]
Veracidad	Alta (reto principal)	Existen riesgos de calidad: valores faltantes en reportes financieros, ruido en noticias generadas por IA, y desalineación temporal entre archivos de distinta granularidad (trades.csv semanal vs. stock_prices.csv diario) [2]



Valor	Alta	El resultado del análisis (ranking predictivo de retornos) tiene un impacto económico directo y medible sobre las decisiones de inversión de un portafolio real [1]
-------	------	---

Conclusión: ¿es Big Data?

El volumen puro de los seis archivos CSV originales del dataset, considerado de forma aislada, no alcanza por sí solo la escala que suele asociarse con Big Data clásico (terabytes/petabytes) [9]. Sin embargo, al evaluar el proyecto de forma integral incorporando las fuentes semiestructuradas y no estructuradas del inventario (TDnet y noticias financieras) se cumplen de manera clara al menos tres de las cinco V's de forma crítica: variedad (tres tipos de estructura de datos distintos), veracidad (múltiples retos de calidad e integración) y valor (impacto económico directo). Por esta razón, se concluye que este proyecto sí puede abordarse bajo un enfoque de Big Data, no tanto por el volumen bruto de datos, sino por la heterogeneidad de fuentes y la complejidad de integración que exige tratar simultáneamente datos numéricos, textuales y semiestructurados provenientes de sistemas oficiales distintos (JPX, TDnet, agencias de noticias) [3], [4], [5].

Reto de veracidad identificado

Como reto de veracidad concreto para este proyecto, se identifica el siguiente: la posible inconsistencia entre el retorno reportado en stock_prices.csv y eventos corporativos relevantes divulgados en financials.csv o en comunicados TDnet que aún no se reflejan en el precio (por



ejemplo, un anuncio de resultados publicado después del cierre del mercado). Este desfase temporal podría introducir ruido en el modelo predictivo si no se detecta y corrige adecuadamente. Para mitigarlo, se propone validar cruzadamente las fechas de divulgación de TDnet contra las fechas de actualización de precios, y descartar o marcar como de baja confianza los registros donde exista una discrepancia temporal significativa.

Ciclo de vida del proyecto

Descripción general

El ciclo de vida de un proyecto de ciencia de datos comprende seis etapas secuenciales pregunta, obtener, limpiar, analizar, visualizar y decidir que guían de manera ordenada el tránsito desde una necesidad de negocio hasta una decisión sustentada en datos. A continuación, se aplica cada etapa de este ciclo al caso específico de predicción de retornos bursátiles en el mercado JPX desarrollado en este trabajo.

Aplicación de las etapas al caso de estudio

Etapas	Aplicación al caso JPX	Herramientas/fuentes involucradas
1. Pregunta	¿Es posible predecir el retorno futuro de cada acción del mercado japonés para construir un portafolio que maximice la diferencia de retorno entre el top 200 y el bottom 200?	Definición del problema de negocio




2. Obtener	Descarga del dataset JPX Tokyo Stock Exchange Prediction desde Kaggle, complementado con datos de TDnet (comunicados) y noticias financieras Nikkei/NQN	stock_prices.csv, financials.csv, options.csv, trades.csv, stock_list.csv, secondary_stock_prices.csv [2]; TDnet [4]; noticias [5]
3. Limpiar	Tratamiento de valores nulos en reportes financieros, detección de outliers en precios, alineación de granularidad temporal (diario vs. semanal), validación cruzada de fechas de divulgación.	Python (Pandas), reglas de validación temporal
4. Analizar	Entrenamiento de un modelo de aprendizaje automático supervisado (regresión/ranking) usando como variable objetivo la columna target de stock_prices.csv	Modelos de ML (ej. Gradient Boosting, LightGBM), variables predictoras de precios y financieras
5. Visualizar	Generación del ranking final de acciones ordenadas de mayor a menor retorno esperado; dashboards de desempeño histórico y comparación sectorial	Visualizaciones (ej. Python/Matplotlib, Power BI)
6. Decidir	Construcción del portafolio: posiciones de compra en el top 200 del ranking y de venta/exclusión en el bottom 200, según la estrategia definida.	Decisión de negocio del inversionista institucional

Diagrama de flujo del ciclo de vida

Figura 2. Ciclo de vida del proyecto de datos aplicado al caso de predicción de retornos JPX.

Elaboración propia, asistida con IA (Claude, Anthropic).



Carácter iterativo del ciclo

Es importante señalar que, si bien el ciclo se presenta de forma lineal para efectos de claridad, en la práctica es un proceso **iterativo**: los resultados obtenidos en la etapa de "Visualizar" y "Decidir" (por ejemplo, un desempeño insuficiente del ranking frente a los retornos reales observados posteriormente) retroalimentan nuevamente la etapa de "Analizar" ajustando el modelo o incluso la etapa de "Obtener", si se determina que se requieren fuentes de datos adicionales (por ejemplo, incorporar más fuentes de noticias o comunicados TDnet para capturar señales que el modelo inicial no logró detectar).

Comparación de enfoques con el trabajo del compañero

Contexto de la comparación

Como se explicó en la introducción de este documento, ambos trabajos individuales parten del **mismo dataset** (JPX Tokyo Stock Exchange Prediction), heredado de las actividades formativas en pareja de las semanas 1 a 4. Sin embargo, cada integrante desarrolló una **pregunta de negocio** y un **enfoque analítico independiente** sobre dicho dataset, con el fin de cumplir el carácter



individual de la actividad calificable. A continuación, se presenta la comparación formal entre ambos enfoques.

Tabla comparativa

Criterio	Mi enfoque: Predicción de retornos	Enfoque del compañero: Volumen de trading institucional
Pregunta de negocio	¿Cómo predecir el retorno futuro de cada acción para construir un portafolio que maximice la diferencia entre el top 200 y el bottom 200?	¿Los patrones de volumen de negociación semanal permiten anticipar movimientos de precio antes de que ocurran, para apoyar decisiones de timing de entrada/salida?
Archivo(s) protagonista(s)	stock_prices.csv y financials.csv	trades.csv (cruzado con stock_prices.csv para validación)
Tipo de analítica dominante	Predictiva, con salida prescriptiva (ranking de compra/venta)	Predictiva, con foco diagnóstico (¿por qué sube el volumen antes del movimiento de precio?)
Tipo de ML	Supervisado — regresión/ranking sobre variable target de retorno	Supervisado — clasificación binaria (sube/baja) o regresión sobre variación de precio, usando volumen como feature principal
Granularidad temporal principal	Diaria (precios)	Semanal (volumen), lo que exige alinear con datos diarios de precio — reto técnico distinto
V crítica del Big Data	Variedad y Veracidad (integración de fuentes heterogéneas)	Veracidad, con énfasis en la agregación temporal (semanal vs. diario) como fuente de pérdida de información



Riesgo ético identificado	Sesgo hacia sectores con más datos históricos disponibles, afectando la equidad del ranking entre empresas grandes y pequeñas	Riesgo de detectar o replicar patrones asociados a manipulación de mercado (ej. pump-and-dump, front-running)
Decisión de negocio habilitada	Composición de un portafolio (qué acciones comprar/vender)	Momento óptimo de entrada/salida de una posición ya definida
Fuentes complementarias del inventario	Noticias financieras (no estructurado) y TDnet (semiestructurado), usadas para explicar variaciones de resultados financieros	Las mismas fuentes complementarias (noticias y TDnet), usadas para detectar anuncios que expliquen picos anómalos de volumen

Conclusión de la comparación

Aunque ambos trabajos comparten el dataset de origen lo cual es coherente con la naturaleza colaborativa de las actividades formativas previas realizadas en pareja, la pregunta de negocio, el archivo protagonista, la granularidad temporal de análisis y el riesgo ético identificado son claramente distintos entre ambos enfoques. Esto evidencia que se trata de **dos análisis individuales, independientes y complementarios** del mismo conjunto de datos, y no de una duplicación del trabajo, cumpliendo así con el carácter individual exigido por la actividad calificable del Corte 1.



Conclusiones

El conjunto de datos JPX Tokyo Stock Exchange Prediction, disponible en Kaggle y respaldado institucionalmente por Japan Exchange Group (JPX), resultó ser una fuente de datos adecuada y suficiente para abordar el problema planteado en este trabajo: la predicción del retorno futuro de acciones del mercado japonés como insumo para la construcción de un portafolio de inversión [1], [2]. El dataset ofrece información estructurada de calidad institucional precios, resultados financieros, opciones y volúmenes de negociación, la cual, complementada con fuentes semiestructuradas (TDnet) y no estructuradas (noticias financieras), permitió construir un inventario de datos completo que cubre los tres tipos de estructura exigidos por la actividad [4], [5].

A partir del análisis realizado, se determinó que el problema corresponde principalmente a un caso de analítica predictiva, con un componente prescriptivo en su etapa final, resuelto mediante aprendizaje automático supervisado, dado que el dataset ya provee una variable objetivo (retorno realizado) sobre la cual entrenar y validar el modelo [2], [10]. Asimismo, aunque el volumen bruto de los archivos originales del dataset no alcanza por sí solo la escala del Big Data clásico, la incorporación de fuentes heterogéneas evidenció que la variedad y la veracidad son las V's más críticas y determinantes en este proyecto, justificando un enfoque de Big Data centrado en la complejidad de integración más que en el volumen puro [9].



En cuanto al ciclo de vida del proyecto, se logró trazar de manera coherente el recorrido completo desde la pregunta de negocio hasta la decisión de inversión, identificando en la etapa de limpieza el principal reto técnico del proyecto: la desalineación temporal entre fuentes de distinta granularidad, como los precios diarios frente a los volúmenes semanales y los comunicados de fecha irregular. Por otra parte, aunque este trabajo y el de mi compañero/a parten del mismo dataset heredado del trabajo colaborativo realizado en las actividades formativas de las semanas 1 a 4, se logró demostrar que las preguntas de negocio, los archivos protagonistas y las decisiones habilitadas por cada enfoque son sustancialmente distintos, cumpliendo así con el carácter individual exigido por la actividad calificable del Corte 1.

El dataset JPX Tokyo Stock Exchange Prediction demostró ser una base de datos robusta, verificable y bien documentada institucionalmente, apta tanto para el desarrollo de las actividades formativas en pareja como para el desarrollo de análisis individuales diferenciados, cumpliendo satisfactoriamente con los cuatro criterios evaluados en la rúbrica de la actividad calificable: problema y pregunta de datos, inventario de fuentes, tipo de analítica y justificación de Big Data, y ciclo de vida del proyecto.



Referencia en formato IEEE

- [1] Kaggle, "JPX Tokyo Stock Exchange Prediction," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/overview>. [Accessed: Aug. 30, 2026].
- [2] Kaggle, "JPX Tokyo Stock Exchange Prediction — Data," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/data>. [Accessed: Aug. 30, 2026].
- [3] Japan Exchange Group, "J-Quants API," *JPX Official Website*, 2026. [Online]. Available: <https://www.jpx.co.jp/english/markets/other-data-services/j-quants-api/>. [Accessed: Aug. 30, 2026].
- [4] Japan Exchange Group, "Overview of TDnet," *JPX Official Website*, 2022. [Online]. Available: <https://www.jpx.co.jp/english/equities/listing/disclosure/tdnet/index.html>. [Accessed: Aug. 30, 2026].
- [5] QUICK Corp., "QUICK APIs — Data Coverage (Nikkei/NQN News)," *QUICK Corporate Website*, 2022. [Online]. Available: <https://corporate.quick.co.jp/en/apis/>. [Accessed: Aug. 30, 2026].
- [6] Japan Exchange Group, "Availability of English Disclosure Information by Listed Companies," *JPX English Disclosure GATE*, 2026. [Online]. Available: <https://www.jpx.co.jp/english/equities/listed-co/disclosure-gate/availability/>. [Accessed: Aug. 30, 2026].
- [7] Japan Exchange Group, "J-Quants Pro," *JPX Official Website*, 2025. [Online]. Available: <https://www.jpx.co.jp/english/markets/other-data-services/j-quants-pro/index.html>. [Accessed: Aug. 30, 2026].
- [8] Japan Exchange Group, "JPxData Portal," *JPX Official Website*, 2026. [Online]. Available: <https://www.jpx.co.jp/english/markets/data-catalog/index.html>. [Accessed: Aug. 30, 2026].
- [9] IBM, "What is Big Data?," *IBM Think*, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>. [Accessed: Aug. 30, 2026].
- [10] Qlik, "Embrace the Future — Make the Move from Descriptive to Prescriptive Analytics," *Qlik Blog*, 2022. [Online]. Available: <https://www.qlik.com/blog/embrace-the-future-moving-from-descriptive-to-prescriptive-analytics>. [Accessed: Aug. 30, 2026].