



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1.

Dossier de Fundamentos: Consolidación del Proyecto de Predicción de Retornos en el Mercado Bursátil de Tokio (JPX)

Iván David Cardzo Charry y Zara Melisa Monroy Vera

Facultad de Ingeniería, Corporación Universitaria del Huila (CORHUILA)

Electiva VI Ciencia de Datos (Cód. 69109) [Pénsum 40D, Grupo 1]

Jesús Ariel González Bonilla

Septiembre 11 de 2026

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Table de Contenidos

Abstract	3
Introducción	4
Objetivos	5
Marco teórico	6
Encuadre del proyecto (Semana 1).....	8
Fuentes de datos y V del Big Data (Semana 2).....	8
Arquitectura de datos propuesta (Semana 3).....	9
Tipos de analítica y riesgo ético (Semana 4).....	10
Conclusiones	11
Referencia en formato IEEE	12





Abstract

This report presents the consolidated dossier that closes the first academic cut of a data science project applied to the Japanese equity market. Rather than introducing new content, this document integrates and refines the four previous deliverables developed for the **JPX Tokyo Stock Exchange Prediction** dataset, published on Kaggle by Japan Exchange Group (JPX) [1], [2]: the business question and expected decision (Week 1), the data inventory with its structure classification and relevant Big Data V's (Week 2), the proposed data architecture (Week 3), and the target analytics types together with an identified ethical risk (Week 4). By bringing these four components together into a single coherent narrative, this dossier demonstrates the complete lifecycle of a data science project's initial framing, from problem definition to architecture design and ethical consideration, before advancing into model development in subsequent phases of the course.

Keywords: *Project consolidation, data lifecycle, business question, data architecture, JPX Tokyo Stock Exchange.*



Introducción

Las cuatro primeras semanas de este corte permitieron desarrollar, de forma progresiva, los fundamentos de un proyecto de ciencia de datos aplicado a la predicción de retornos en el mercado bursátil de Tokio: se formuló una pregunta de negocio y su decisión asociada, se identificaron y clasificaron las fuentes de datos disponibles evaluando su relevancia frente a las V del Big Data, se diseñó una arquitectura de datos justificada, y se clasificaron los tipos de analítica aplicables junto con un riesgo ético relevante. Cada uno de estos componentes fue desarrollado de manera independiente semana a semana; sin embargo, un proyecto real de ciencia de datos exige que estas piezas se articulen como un todo coherente, y no como entregas aisladas.

El presente documento tiene como propósito **consolidar** estos cuatro componentes en un único dossier, mejorando la redacción y coherencia de cada parte a la luz de lo aprendido en las semanas posteriores. Este ejercicio de integración permite verificar que las decisiones tomadas en cada etapa la pregunta de negocio, las fuentes de datos, la arquitectura y el enfoque analítico sean mutuamente consistentes entre sí, cerrando así el primer corte de la asignatura con una base sólida sobre la cual construir el desarrollo técnico del proyecto en las siguientes etapas.





Objetivos

1. Objetivo general

Consolidar en un dossier único e integrado los fundamentos desarrollados durante las primeras cuatro semanas del proyecto de predicción de retornos en el mercado bursátil de Tokio, verificando la coherencia entre la pregunta de negocio, el inventario de datos, la arquitectura propuesta y el enfoque analítico seleccionado.

2. Objetivos específicos

- Integrar la pregunta de negocio y la decisión esperada definidas en la Semana 1.
- Consolidar las fuentes de datos, su clasificación y las V relevantes del Big Data identificadas en la Semana 2.
- Presentar la arquitectura de datos propuesta en la Semana 3.
- Reunir los tipos de analítica objetivo y el riesgo ético identificado en la Semana 4.





Marco teórico

Un proyecto de ciencia de datos no se desarrolla como una serie de entregas aisladas, sino como un **ciclo de vida integrado**, en el cual cada etapa se apoya en las decisiones tomadas en la etapa anterior: la pregunta de negocio determina qué datos son necesarios, los datos determinan qué arquitectura resulta adecuada, y tanto los datos como la arquitectura determinan qué tipo de analítica es viable aplicar [3], [4]. Este dossier de cierre se fundamenta precisamente en la necesidad de verificar dicha coherencia interna antes de avanzar hacia etapas de modelamiento más avanzadas.

En este sentido, resultan relevantes tres conceptos ya desarrollados en semanas anteriores. Primero, la **clasificación de datos según su nivel de estructura** (estructurado, semiestructurado, no estructurado), que determinó la elección de un data lake sobre un data warehouse [3]. Segundo, el modelo de las **cinco V's del Big Data** (volumen, velocidad, variedad, veracidad, valor), utilizado para justificar por qué la variedad y la veracidad de las fuentes exigían una arquitectura flexible y validaciones de calidad específicas [3]. Y tercero, el modelo de los **cuatro tipos de analítica** (descriptiva, diagnóstica, predictiva, prescriptiva), que permitió anticipar desde una etapa temprana que el proyecto requeriría aprendizaje automático supervisado, dado que la pregunta de negocio exige tanto anticipar un resultado futuro como recomendar una acción concreta [4].



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

7.

La articulación coherente de estos tres marcos conceptuales estructura de datos, dimensiones de Big Data y tipos de analítica constituye la base teórica sobre la cual se sustenta la consolidación presentada en este dossier.

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8360699
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA

"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"



Encuadre del proyecto (Semana 1)

Pregunta de negocio:

¿Es posible predecir el retorno futuro de cada acción del mercado bursátil japonés, con el fin de generar un ranking que maximice la diferencia de retorno entre las 200 acciones con mejor desempeño esperado y las 200 con peor desempeño esperado?

Decisión esperada: el resultado del análisis un ranking predictivo de retornos habilita la composición de un portafolio de inversión, asignando posiciones de compra a las 200 acciones con mayor retorno esperado y posiciones de venta o exclusión a las 200 con menor retorno esperado [1].

Fuentes de datos y V del Big Data (Semana 2)

#	Fuente	Tipo de dato
1-5	stock_prices.csv, financials.csv, options.csv, trades.csv, stock_list.csv	Estructurado
6	Comunicados TDnet (TSE)	Semiestructurado
7	Noticias financieras Nikkei/NQN	No estructurado



V's críticas: **Variedad** (combinación de tres niveles de estructura) y **Veracidad** (riesgo de datos faltantes y desalineación temporal entre fuentes de distinta granularidad) [3], [5], [6].

Reto de veracidad: desalineación temporal entre `financials.csv`, `TDnet` y `stock_prices.csv`, detectable mediante validación de completitud y validación cruzada de fechas [5].

Arquitectura de datos propuesta (Semana 3)

Flujo: Fuentes → Ingesta batch → Data Lake → Procesamiento (limpieza y transformación) → Análisis/BI.

Decisiones justificadas:

- **Data Lake** (no warehouse): por la variedad de estructuras de datos, que exigiría transformación previa innecesaria en un esquema de warehouse.
- **Batch** (no streaming): por la frecuencia diaria/semanal de actualización de las fuentes, sin necesidad de respuesta en tiempo real.

Herramientas candidatas: Apache Airflow (ingesta), Python/Pandas (procesamiento), Power BI (BI/visualización).



Tipos de analítica y riesgo ético (Semana 4)

Tipo	Pregunta
Descriptiva	¿Cuál fue el retorno promedio del sector tecnológico japonés el último trimestre?
Diagnóstica	¿Por qué ciertas acciones tuvieron retornos negativos?
Predictiva	¿Cuál será el retorno futuro de cada acción?
Prescriptiva	¿Qué acciones incluir en el top/bottom 200 del portafolio?

Tipo de ML: supervisado, dado que el dataset ya contiene una variable objetivo etiquetada (columna *target*) [2].

Riesgo ético: sesgo hacia empresas con mayor disponibilidad de datos históricos. **Mitigación:** segmentar la evaluación del modelo por tamaño de empresa y establecer un umbral mínimo de calidad de datos.



Conclusiones

El presente dossier logró consolidar en un documento único e integrado los fundamentos desarrollados durante las primeras cuatro semanas del proyecto de predicción de retornos en el mercado bursátil de Tokio, verificando la coherencia entre la pregunta de negocio, el inventario de datos, la arquitectura propuesta y el enfoque analítico seleccionado.

Se integró la pregunta de negocio y la decisión esperada definidas en la Semana 1, confirmando que ambas siguen siendo consistentes con el enfoque predictivo desarrollado en las semanas posteriores.

Se consolidaron las fuentes de datos, su clasificación y las V relevantes del Big Data identificadas en la Semana 2, verificando que la variedad y veracidad de dichas fuentes fueron precisamente los criterios que orientaron la decisión de arquitectura tomada en la Semana 3.

Se presentó la arquitectura de datos propuesta en la Semana 3, confirmando que las decisiones de data lake y procesamiento batch responden directamente a las características de las fuentes identificadas previamente.

Finalmente, se reunieron los tipos de analítica objetivo y el riesgo ético identificado en la Semana 4, cerrando así el corte con un encuadre completo, coherente y técnicamente fundamentado del proyecto, listo para avanzar hacia las etapas de desarrollo del modelo predictivo.



Referencia en formato IEEE

- [1] Kaggle, "JPX Tokyo Stock Exchange Prediction," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/overview>. [Accessed: Aug. 31, 2026].
- [2] Kaggle, "JPX Tokyo Stock Exchange Prediction — Data," *Kaggle Competitions*, 2022. [Online]. Available: <https://www.kaggle.com/competitions/jpx-tokyo-stock-exchange-prediction/data>. [Accessed: Aug. 31, 2026].
- [3] IBM, "What is Big Data?," *IBM Think*, 2026. [Online]. Available: <https://www.ibm.com/think/topics/big-data>. [Accessed: Aug. 31, 2026].
- [4] Qlik, "Embrace the Future — Make the Move from Descriptive to Prescriptive Analytics," *Qlik Blog*, 2022. [Online]. Available: <https://www.qlik.com/blog/embrace-the-future-moving-from-descriptive-to-prescriptive-analytics>. [Accessed: Aug. 31, 2026].
- [5] Japan Exchange Group, "Overview of TDnet," *JPX Official Website*, 2022. [Online]. Available: <https://www.jpx.co.jp/english/equities/listing/disclosure/tdnet/index.html>. [Accessed: Aug. 31, 2026].
- [6] QUICK Corp., "QUICK APIs — Data Coverage (Nikkei/NQN News)," *QUICK Corporate Website*, 2022. [Online]. Available: <https://corporate.quick.co.jp/en/apis/>. [Accessed: Aug. 31, 2026].